

Relatório Técnico - Tech Challenge Fase 3

Assistente médico virtual com fine-tuning QLoRA, RAG e LangGraph

Pós-graduação: IA para Devs

Instituição: FIAP + Alura

Fase: Fase 3

Desafio: Tech Challenge

Integrante:

- Fábio Rodrigues Barbosa

Data: 15/09/2026

Links da entrega

- **Repositório Git:**
<https://github.com/fabiorbarbosa/pos-tech-fiap/tree/main/fase-03/tech-challenge>
- **Vídeo de demonstração:**
<https://vimeo.com/1210042989>

1. Introdução

Este projeto apresenta um assistente médico virtual para apoio à decisão clínica, desenvolvido no contexto do Tech Challenge da Fase 3 da pós-graduação IA para Devs. A solução combina fine-tuning de uma LLM com dados médicos sintéticos, recuperação de protocolos institucionais e um fluxo orquestrado para consulta de prontuário, aplicação de guardrails, geração de resposta e auditoria.

O objetivo não é substituir o julgamento médico nem emitir prescrição. O assistente organiza informações de protocolos e do prontuário sintético para apoiar uma resposta contextualizada, sempre com indicação das fontes utilizadas e com mecanismos explícitos de bloqueio para solicitações inadequadas.

2. Definição do problema

O cenário proposto representa um hospital que deseja disponibilizar aos médicos um assistente capaz de responder dúvidas sobre condutas institucionais, consultar informações estruturadas de pacientes e sugerir procedimentos com base em protocolos internos.

O problema possui três necessidades complementares:

- adaptar uma LLM ao domínio médico institucional;
- recuperar conteúdo confiável de protocolos e combinar esse conteúdo ao contexto do paciente;
- controlar riscos de uso por meio de limites de atuação, validação humana e trilha de auditoria.

Por se tratar de um domínio sensível, a entrega foi estruturada como apoio à decisão. Respostas que envolvem prescrição direta são bloqueadas e respostas com dose ou posologia exigem validação médica obrigatória.

3. Base utilizada

A base utilizada é integralmente sintética. Não há dados reais de pacientes, profissionais ou prontuários. O conjunto reproduz apenas o formato de informações internas necessárias para demonstrar o fluxo técnico.

Os arquivos de origem estão em `data/seed/` :

- `protocols.json` : 10 protocolos institucionais, incluindo sepse, síndrome coronariana aguda, diabetes tipo 2, TEV e insuficiência cardíaca;
- `faq.json` : 14 perguntas frequentes com respostas que citam fontes;
- `templates.json` : modelos de laudo, receituário e checklist de procedimento.

O pipeline de curadoria aplica anonimização de identificadores pessoais, deduplicação de perguntas, enriquecimento com variações de contexto e divisão holdout reprodutível de 80/20. Como resultado, foram gerados 41 exemplos de treino em `train.jsonl` e 10 exemplos de avaliação em `eval.jsonl`.

Essa escolha mantém o trabalho aderente ao escopo acadêmico e à LGPD, sem apresentar dados sintéticos como se fossem evidência clínica real.

4. Fine-tuning e modelagem

O modelo base escolhido foi `Qwen/Qwen2.5-0.5B-Instruct`. O seu porte permite demonstração local e fine-tuning com recursos acessíveis, mantendo compatibilidade com execução em GPU de

Colab e com validações locais em Apple Silicon.

O fine-tuning foi implementado com QLoRA, usando quantização NF4 de 4 bits e adaptadores LoRA com $r=16$ e $\alpha=32$. O treinamento supervisionado utiliza SFTTrainer, template de chat do tokenizer e os seguintes parâmetros principais:

- 3 épocas;
- learning rate $2e-4$ com scheduler coseno;
- batch size 4 com acumulação 4;
- sequência máxima 1024;
- avaliação em holdout separado do treino.

O notebook notebooks/finetuning_colab.ipynb documenta a execução em GPU. O comando `python -m src.fine_tuning.train --dry-run` valida localmente os dados, o prompt e a tokenização sem iniciar o treinamento completo.

5. Arquitetura do assistente

O assistente foi construído de forma modular em Python. O fluxo principal usa LangChain e LangGraph, enquanto o prontuário é simulado em SQLite e os protocolos são recuperados por FAISS, com fallback lexical para o modo offline.

O fluxo implementado é:

1. receber pergunta e identificador opcional do paciente;
2. aplicar guardrail de entrada;
3. consultar contexto do prontuário e protocolos relevantes;
4. gerar resposta com o contexto recuperado;
5. validar a saída e incluir fontes;
6. registrar auditoria estruturada em JSONL.

Os componentes principais estão organizados em `src/assistant/`, `src/db/`, `src/data_prep/` e `src/fine_tuning/`. Essa separação permite reproduzir e testar o fluxo sem depender de interface gráfica ou de dados externos.

6. Segurança, explicabilidade e auditoria

A solução possui três camadas de controle:

- **Guardrails de entrada:** bloqueiam pedidos de prescrição ou ajuste direto e redirecionam cenários de emergência para atendimento imediato.

- **Validação de saída:** adiciona aviso de validação médica quando há menção a dose ou posologia e exige a indicação das fontes recuperadas.
- **Auditoria:** grava cada interação em `logs/audit.jsonl` , com pergunta, resposta, paciente, fontes citadas, status de bloqueio e necessidade de validação humana.

Os protocolos recuperados incluem identificadores como `PR0T-001` , o que permite rastrear a origem da resposta. O modo `--mock` utiliza busca lexical local e não inicializa embeddings, índice vetorial ou rede, preservando uma demonstração realmente offline.

7. Experimentos e resultados

A avaliação utiliza o holdout de 10 exemplos e duas métricas: ROUGE-L médio, como medida de similaridade lexical com a resposta de referência, e taxa de citação de fonte, como proxy de explicabilidade.

Resultados consolidados:

Variante	Itens avaliados	ROUGE-L médio	Taxa de citação de fonte
Qwen2.5-0.5B-Instruct base	10	0.0671	0%
QLoRA fine-tuned	10	0.0933	80%

O modelo fine-tuned apresentou aumento de ROUGE-L sobre a linha de base e, principalmente, passou a citar fontes na maior parte das respostas avaliadas. Esse resultado é relevante porque a fonte do protocolo é necessária para a conferência humana da resposta.




Figura 1. ROUGE-L médio e taxa de citação de fonte na avaliação final do modelo QLoRA fine-tuned.

Também foram executados cenários qualitativos em modo offline:

Cenário	Resultado esperado	Resultado obtido
Conduta em protocolo	resposta com fontes	fontes de protocolo citadas
Prescrição direta	bloqueio do pedido	bloqueado pelo guardrail de entrada
Emergência	redirecionamento imediato	mensagem de orientação para atendimento imediato
Contexto do paciente	uso de prontuário	exames pendentes e fontes retornados

Os artefatos de resultado estão em `results/eval_results_final.json` e `results/VALIDACAO_FINAL.md`.

8. Reprodução

Crie um ambiente Python 3.12 e instale as dependências:

```
pip install -r requirements.txt
```

Execute o fluxo de reprodução:

```
python scripts/setup_all.py
python tests/test_smoke.py
python main.py --mock --demo
python -m src.fine_tuning.train --dry-run
```

O pacote também contém um `Dockerfile` que executa o demo em modo `--mock`. A entrega final foi validada com sete smoke tests, demo offline e dry-run de treino.

9. Discussão crítica

Os resultados demonstram a viabilidade técnica de combinar adaptação leve de LLM, recuperação de conhecimento institucional e fluxo orquestrado para apoio à decisão. A separação entre

protocolos, prontuário, guardrails e auditoria torna explícito o caminho usado para responder cada solicitação.

Entretanto, a solução não deve ser usada em produção clínica sem validação adicional. O dataset é sintético, a avaliação possui amostra pequena e a métrica ROUGE-L não mede segurança clínica. O modelo base de 0,5B também pode repetir trechos em inferência e não substitui revisão humana.

Como evolução, recomenda-se avaliar modelos maiores, ampliar o conjunto de avaliação, submeter protocolos e respostas a revisão clínica formal e reforçar a validação semântica dos guardrails.

10. Conclusão

O projeto atende ao objetivo da Fase 3 ao entregar um assistente médico virtual modular, com fine-tuning QLoRA, recuperação de protocolos, consulta estruturada de prontuário, LangGraph, guardrails, auditoria e explicabilidade por fonte.

Além da implementação, a entrega inclui testes offline, notebook de fine-tuning, adaptador LoRA final, resultados de avaliação, visualização e instruções de reprodução. O trabalho permanece explicitamente posicionado como demonstrador acadêmico de apoio à decisão, sem substituir julgamento clínico ou validação médica.