

Relatório Técnico - Tech Challenge B

1. Introdução

Este projeto apresenta uma solução inicial de Inteligência Artificial aplicada ao apoio à triagem médica, com foco na classificação binária de indicativo de diabetes a partir de dados clínicos tabulares.

O problema foi modelado como uma tarefa de classificação supervisionada, em que o objetivo é prever a variável `Outcome`, indicando se a paciente pertence à classe com indicativo positivo de diabetes (`1`) ou não (`0`).

A proposta está alinhada ao contexto de apoio à análise inicial de exames e dados médicos, sem substituir a decisão clínica profissional.

2. Definição do problema

O problema escolhido foi a predição de indicativo de diabetes com base em variáveis clínicas e demográficas. Em termos práticos, a solução busca responder se atributos como glicose, pressão arterial, insulina, IMC, idade e histórico familiar permitem distinguir pacientes com maior probabilidade de apresentar diabetes.

Trata-se de uma tarefa de classificação binária em saúde, na qual o impacto dos erros deve ser analisado com cuidado. Em particular, falsos negativos são mais sensíveis, pois podem deixar de sinalizar pacientes potencialmente positivos para investigação adicional.

3. Dataset utilizado

- Nome: `Diabetes Dataset`
- Fonte: [Kaggle - mathchi/diabetes-data-set](#)
- Arquivo utilizado: `diabetes.csv`
- Variável-alvo: `Outcome`

O dataset contém 768 registros e 9 colunas, sendo 8 variáveis preditoras e 1 variável-alvo. As variáveis principais incluem:

- `Pregnancies`
- `Glucose`
- `BloodPressure`

- SkinThickness
- Insulin
- BMI
- DiabetesPedigreeFunction
- Age
- Outcome


O uso desse dataset foi escolhido por sua clareza estrutural, ampla utilização em estudos educacionais de Machine Learning e boa adequação ao problema proposto.

4. Exploração dos dados

Na inspeção inicial, verificou-se que a base não possui valores nulos formais nem registros duplicados. Ainda assim, a análise exploratória mostrou que parte das variáveis apresenta zeros clinicamente suspeitos, o que indica inconsistências semânticas nos dados.

A distribuição da variável-alvo mostrou desbalanceamento moderado, com predominância da classe negativa. Esse comportamento justificou o uso de métricas além da acurácia nas etapas de modelagem.

A Figura 1 apresenta a distribuição da variável-alvo.



A Tabela 1 apresenta a distribuição da variável `Outcome` , mostrando a proporção entre pacientes sem indicativo e com indicativo de diabetes.

Tabela 1. Distribuição da variável-alvo (`target-summary.csv`)

Outcome	Contagem	Percentual (%)
0	500	65,10
1	268	34,90

As estatísticas descritivas mostraram diferenças relevantes de escala entre os atributos, além da presença de valores mínimos iguais a zero em variáveis clínicas como `Glucose` , `BloodPressure` , `SkinThickness` , `Insulin` e `BMI` , sugerindo possível ocorrência de valores ausentes disfarçados.

A análise de zeros suspeitos destacou principalmente as variáveis `Insulin` e `SkinThickness` , que concentraram as maiores proporções de valores iguais a zero. Esse resultado reforça a interpretação de que parte desses registros pode representar ausência de medição, e não observações clínicas reais.


Tabela 2. Quantidade e percentual de zeros suspeitos (`zero-summary.csv`)

Variável	Zeros	Percentual de zeros (%)
Insulin	374	48,70
SkinThickness	227	29,56
BloodPressure	35	4,56
BMI	11	1,43
Glucose	5	0,65

Também foi observada coerência entre a análise exploratória e a leitura visual das distribuições: variáveis como `Glucose` e `BMI` apresentaram comportamento mais estável, enquanto `Insulin` mostrou maior assimetria, concentração de zeros e sensibilidade a valores extremos.

Além disso, a matriz de correlação indicou que `Glucose` apresenta a relação linear mais forte com a variável-alvo, seguida por `BMI` , `Age` e `Pregnancies` . As magnitudes observadas não sugerem multicolinearidade extrema entre os atributos.

A Figura 2 apresenta a matriz de correlação entre os atributos numéricos da base.



5. Pré-processamento

Com base na análise exploratória, foi definida uma estratégia de pré-processamento voltada à consistência metodológica e à adequação clínica dos dados para a modelagem.

As principais decisões adotadas foram:

- separação entre variáveis preditoras e variável-alvo;
- tratamento de zeros suspeitos como valores ausentes nas colunas `Glucose` , `BloodPressure` , `SkinThickness` , `Insulin` e `BMI` ;
- manutenção de `Pregnancies` sem esse tratamento, pois o valor zero pode ser clinicamente válido;
- imputação de valores ausentes por mediana;
- padronização das variáveis numéricas;
- encapsulamento do fluxo em pipeline para evitar vazamento de dados.

A imputação por mediana foi escolhida por sua maior robustez frente a assimetrias e valores extremos, especialmente em variáveis como `Insulin` . Já a padronização foi aplicada para lidar

com diferenças relevantes de escala entre os atributos, favorecendo modelos sensíveis à magnitude das variáveis.

Além disso, os dados foram divididos em conjuntos de treino e teste com estratificação pela variável-alvo, preservando a proporção original das classes e garantindo maior consistência na etapa de avaliação.

6. Modelagem

Foram comparados dois modelos de classificação supervisionada:

- `LogisticRegression`
- `RandomForest`

A regressão logística foi utilizada como baseline por sua simplicidade, interpretabilidade e uso frequente em problemas de classificação binária. Já o modelo `RandomForest` foi escolhido por sua capacidade de capturar relações não lineares e apresentar boa robustez em problemas tabulares com múltiplos atributos numéricos.

Para garantir comparabilidade justa entre os modelos, ambos foram executados com o mesmo pipeline de pré-processamento, a mesma divisão entre treino e teste e o mesmo conjunto de variáveis preditoras. Dessa forma, a comparação de desempenho passou a refletir principalmente as diferenças entre os algoritmos, e não variações no tratamento dos dados.

7. Avaliação dos modelos

A avaliação dos modelos foi realizada com base nas métricas `accuracy`, `recall` e `F1-score`, considerando o conjunto de teste. Essas métricas foram escolhidas porque, em contexto de saúde, a acurácia não deve ser interpretada isoladamente. O `recall` da classe positiva é especialmente relevante, pois está relacionado à capacidade de identificar corretamente pacientes com indicativo de diabetes, enquanto o `F1-score` contribui para avaliar o equilíbrio entre detecção de casos positivos e controle de erros.

A Tabela 3 apresenta os resultados obtidos pelos modelos avaliados.

Tabela 3. Resultados comparativos entre os modelos (`metricas-modelos.csv`)

Modelo	Accuracy	Recall	F1-score
RandomForest	0,77	0,61	0,65
LogisticRegression	0,71	0,50	0,55

Os resultados mostram que o modelo `RandomForest` apresentou desempenho superior ao da `LogisticRegression` em todas as métricas consideradas. Em especial, o ganho em `recall` foi tratado como fator decisivo, pois reduz o risco de deixar de identificar pacientes potencialmente positivos, aspecto mais sensível no problema analisado.

Assim, a avaliação quantitativa indica que a `RandomForest` oferece melhor equilíbrio entre desempenho global e capacidade de identificação correta da classe positiva.

8. Matriz de confusão e análise dos erros

A análise da matriz de confusão permite compreender com mais clareza como o modelo final se comporta em relação aos diferentes tipos de erro. No contexto deste problema, essa leitura é especialmente importante porque falsos negativos representam pacientes com possível indicativo de diabetes que deixariam de ser sinalizados para investigação adicional.

A Figura 3 apresenta a matriz de confusão do modelo `RandomForest`, enquanto a Tabela 4 resume seus componentes.




Tabela 4. Componentes da matriz de confusão do modelo RandomForest
(matriz-confusao-randomforest.csv)

Verdadeiro Negativo	Falso Positivo	Falso Negativo	Verdadeiro Positivo
86	14	21	33

Os resultados mostram que o modelo obteve boa capacidade de identificar corretamente tanto casos negativos quanto positivos. Em especial, a quantidade de falsos negativos foi reduzida em relação ao modelo baseline, o que reforça a adequação do RandomForest ao contexto analisado. Embora ainda existam erros de classificação, o comportamento observado indica melhor equilíbrio entre sensibilidade e desempenho global, aspecto importante para aplicações de apoio à triagem.


9. Interpretabilidade

A interpretabilidade do modelo final foi analisada com base na importância das variáveis e em visualizações com SHAP, com o objetivo de verificar se os sinais utilizados na predição são coerentes com o contexto clínico do problema.

A Tabela 5 apresenta a importância das variáveis no modelo RandomForest , enquanto a Figura 4 mostra a visualização gráfica dessa relevância.


Tabela 5. Importância das variáveis no modelo RandomForest
(importancia-variaveis-randomforest.csv)

Variável	Importância
Glucose	0,27
BMI	0,16
DiabetesPedigreeFunction	0,12
Age	0,11
Insulin	0,09
BloodPressure	0,08
Pregnancies	0,08
SkinThickness	0,07



Os resultados mostram que **Glucose** foi a variável mais relevante para o modelo final, seguida por **BMI**, **DiabetesPedigreeFunction** e **Age**. Esse padrão é amplamente coerente com os achados da análise exploratória, especialmente no destaque anterior de **Glucose** e **BMI** como atributos com maior potencial discriminativo.

Além da importância global das variáveis, foi utilizada uma análise com SHAP para complementar a interpretação do comportamento do modelo. A Figura 5 apresenta a visualização-resumo dessa análise.



A leitura conjunta dessas evidências reforça a consistência entre a etapa exploratória e a modelagem, sugerindo que o modelo se apoia em sinais clinicamente plausíveis, e não em padrões arbitrários ou de difícil justificativa.

Esse alinhamento entre análise exploratória e interpretabilidade fortalece a confiança nos resultados, pois sugere que o modelo está se apoiando em atributos clinicamente plausíveis.

10. Discussão crítica

Os resultados obtidos mostram que a solução possui potencial como ferramenta de apoio à triagem, especialmente pela capacidade do modelo final de identificar pacientes com indicativo positivo com desempenho superior ao baseline. Ainda assim, a interpretação dos resultados deve ser feita com cautela, considerando as limitações do experimento.

Uma das principais limitações está no próprio dataset utilizado, que representa um recorte populacional específico e relativamente pequeno. Esse fator reduz a capacidade de generalização dos resultados para outras populações e contextos clínicos. Além disso, a presença de zeros clinicamente suspeitos em variáveis relevantes exigiu tratamento no pré-processamento, o que reforça a existência de limitações de qualidade de dados.

Também é importante destacar que o desempenho observado se refere a uma base específica e a uma configuração experimental acadêmica, não devendo ser interpretado como validação clínica ampla. Embora o modelo `RandomForest` tenha apresentado melhor equilíbrio entre desempenho global e identificação de casos positivos, sua aplicação prática exigiria novas etapas de validação, inclusive em bases adicionais e em cenários operacionais distintos.

Assim, os resultados devem ser entendidos como evidência de viabilidade analítica da abordagem proposta, e não como solução pronta para implantação clínica.

11. Uso prático e implicações éticas

O uso mais adequado da solução proposta é como ferramenta de apoio à triagem ou à priorização de casos, e não como substituição da decisão médica. Em um cenário prático, o modelo poderia auxiliar profissionais de saúde a identificar pacientes com maior probabilidade de apresentar indicativo de diabetes, contribuindo para encaminhamentos, investigação complementar e organização do atendimento.

Ainda assim, qualquer aplicação em contexto real exigiria supervisão profissional contínua, uma vez que erros de classificação podem produzir impacto sobre pessoas reais. Nesse sentido, a interpretação dos resultados deve considerar limitações do dataset, risco de falsos negativos e necessidade de avaliação clínica complementar.

Do ponto de vista ético e operacional, também seria necessário observar requisitos de segurança, privacidade e confidencialidade dos dados, bem como princípios de uso responsável da informação em saúde. Dessa forma, o valor da solução está em apoiar a análise inicial de risco, preservando o papel central do profissional de saúde na decisão final.

12. Conclusão

O projeto mostrou que é possível construir uma solução inicial de Machine Learning para apoio à identificação de indicativo de diabetes a partir de dados clínicos tabulares. A análise exploratória permitiu compreender a estrutura da base, identificar inconsistências relevantes e definir uma estratégia de pré-processamento coerente com o problema.

Na etapa de modelagem, o modelo `RandomForest` apresentou o melhor equilíbrio entre desempenho global e capacidade de identificar corretamente casos positivos, superando a `LogisticRegression` nas métricas analisadas. A análise de interpretabilidade também se mostrou coerente com os achados exploratórios, especialmente no destaque de variáveis como `Glucose`, `BMI` e `Age`.

Em conjunto, os resultados indicam que a abordagem possui potencial como ferramenta de apoio à triagem, desde que respeitadas as limitações da base, a necessidade de validação adicional e o papel indispensável da supervisão profissional em contextos reais.